

SOLUNUM SESLERİ PROJESİ

NİDA SEBAHAT ZEREN /24458667018

Bu proje kapsamında, solunum seslerinden oluşan bir veri seti kullanılarak derin öğrenme tabanlı bir sınıflandırma sistemi geliştirilmiştir. Ses verileri doğrudan kullanılmak yerine, derin öğrenme modellerinin görsel örüntüleri daha etkili öğrenebilmesi amacıyla görüntü formatına dönüştürülmüştür. Bu dönüşüm sürecinde ses sinyalleri spektrogram görüntülerine çevrilmiş ve böylece zaman-frekans ilişkileri görsel olarak temsil edilmiştir.

Elde edilen görüntüler üzerinde Evrişimsel Sinir Ağları (CNN) mimarisi kullanılarak üç farklı model eğitilmiş ve performansları karşılaştırılmıştır. Modellerin eğitim süreçlerinde veri ön işleme, veri artırma (data augmentation), eğitim-doğrulama-test ayrımı ve performans değerlendirme aşamaları uygulanmıştır. Başarım değerlendirmesinde doğruluk (accuracy), kesinlik (precision), duyarlılık (recall) ve F1 skoru gibi metriklerden yararlanılmıştır.

Bu çalışmanın temel amacı, solunum seslerinden elde edilen görüntüler aracılığıyla hastalık sınıflandırması gerçekleştirebilen ve klinik karar destek sistemlerinde kullanılabilecek bir yapay zekâ modeli geliştirmektir. Ayrıca farklı CNN tabanlı modellerin performanslarının karşılaştırılmasıyla, solunum sesi sınıflandırma problemlerinde hangi mimarilerin daha başarılı sonuçlar verdiğinin ortaya konulması hedeflenmiştir.

SİSTEM MİMARİSİ

Süreç şu adımlardan oluşmaktadır:

1. Ham Ses Girişi ve Okuma: ICBHI veri tabanından alınan **.wav** formatındaki çok kanallı ve heterojen solunum sesleri, metaveri yönergeleri doğrultusunda her bir nefes periyoduna (solunum döngüsüne) ait başlangıç ve bitiş saniyelerine göre kırılarak sisteme yüklenir.
2. Dijital Sinyal İşleme ve Gürültü Filtreleme: Yüklenen ham ses sinyallerine, steteskop sürtünmesi ve kalp atışı gibi klinik dışı parazitleri engellemek adına 50 Hz - 4000 Hz kesim frekanslarına sahip Butterworth bant geçiren (*bandpass*) filtre uygulanır.
3. Zamansal Standardizasyon (Padding/Trimming): Giriş tensörlerinin homojen matris yapısına kavuşturulması amacıyla, filtre edilen sinyaller sabit bir süreye (5 saniye) eşitlenir; kısa sinyallerin sonuna sıfır eklenirken (*zero-padding*), uzun sinyaller kırpılır (*trimming*).
4. Zaman-Frekans Dönüşümü (Mel-Spektrogram Çıkarımı): Logaritmik insan işitme algısına uygun öznitelik haritaları elde etmek amacıyla sinyale Kısa Zamanlı Fourier Dönüşümü (STFT) ve Mel ölçeklemesi uygulanarak genlik değerleri desibel (dB) cinsinden hesaplanır.
5. Görsel Optimizasyon ve Klasörleme: Elde edilen spektrogram matrisi 0-255 piksel aralığına normalize edilerek RGB (COLORMAP_JET) ısı haritasına

dönüştürülür, ImageNet standartlarına uygun olarak 224x224 boyutuna getirilir ve veri sızıntısını (*data leakage*) önleyecek şekilde hasta bazlı (*patient-level*) olarak Train / Validation / Test dizinlerine dağıtılır.

6. İki Aşamalı Model Optimizasyonu: Standart veri yükleyiciler vasıtasıyla çekilen görseller, önceden ImageNet üzerinde eğitilmiş MobileNetV2, DenseNet121 ve Xception mimarilerine beslenir. İlk aşamada temel ağırlıklar dondurularak transfer öğrenmesi uygulanır; ikinci aşamada ise son 30 katmanın kilitleri açılarak mikro öğrenme oranıyla ince ayar (*fine-tuning*) gerçekleştirilir.
7. Metrik ve Grafik Raporlaması: Eğitilen en başarılı model ağırlıkları diske kaydedilirken; test setindeki hiç görülmemiş hastalar üzerinden karmaşıklık matrisleri, ROC eğrileri ve istatistiksel metrik raporları üretilir.
8. Canlı Çıkarım (Inference): Sisteme sunulan yeni ve bağımsız bir **.wav** dosyası, eğitim hattındaki ön işleme adımlarından geçirilerek en iyi performans gösteren fine-tuned modele gönderilir ve Normal, Crackle, Wheeze veya Both sınıflarına ait olasılıksal güven skorları (*confidence scores*) üretilir.

Veri Seti ve Ön İşleme Süreci

Bu çalışmada, solunum yollarındaki patolojik durumların tespit edilmesi amacıyla Kaggle platformunda açık erişime sunulan "ICBHI Respiratory Sound Database" veri seti kullanılmıştır. Göğüs kafesinin farklı bölgelerinden klinik ortamda dijital stetoskoplar aracılığıyla alınan ses kayıtlarını içeren bu veri seti, akciğer sağlığının izlenmesi ve solunum anomalilerinin otomatik olarak sınıflandırılması için oluşturulmuştur. Çalışma kapsamında incelenen veri setinde, çeşitli zaman uzunluklarına ve birbirinden farklı akustik karakteristiklere sahip toplam 6898 adet solunum döngüsü kaydı bulunmaktadır. Uzman hekimler tarafından etiketlenen bu kayıtlar, klinik bulgular doğrultusunda dört temel kategoriye ayrılmıştır; veri seti içerisinde 3642 adet sağlıklı solunum (Normal), 1864 adet çıtırtı (Crackle), 886 adet hırıltı (Wheeze) ve her iki patolojinin aynı anda gözlemlendiği 506 adet karma (Both) ses örneği yer almaktadır.

Derin öğrenme mimarilerinin, ham ses sinyalleri içerisindeki karmaşık örüntüleri etkili bir şekilde öğrenebilmesi için ses verilerinin modele sunulmadan önce kapsamlı bir ön işleme sürecinden geçmesi zorunludur. Bu sürecin temel amacı, sinyal kalitesini standardize ederek modelin yalnızca solunum yollarına ait patolojik frekans desenlerine odaklanmasını sağlamaktır. Bu doğrultuda ilk aşamada, kalp atışları gibi düşük frekanslı fizyolojik gürültüler ile ortamdaki yüksek frekanslı cihaz parazitlerini ortadan kaldırmak amacıyla ham ses kayıtlarına 50-4000 Hz aralığında bir bant geçiren (bandpass) filtre uygulanmıştır. Ardından, evrişimli sinir ağlarının (CNN) sabit boyutlu giriş tensörleri gerektirmesi sebebiyle, tüm ses sinyallerine kırpma (trimming) veya eksik kısımları sıfır ile tamamlama (padding) işlemleri uygulanarak kayıtlar standart bir uzunluğa sabitlenmiştir. Son olarak, kayıtların alındığı farklı cihazlardan

veya mikrofon mesafelerinden kaynaklanan genlik (ses şiddeti) farklılıklarının modelin karar mekanizmasını yanıltmasını engellemek amacıyla tüm sinyaller normalize edilmiştir.

Gerçekleştirilen bu sistematik ön işleme adımları, sınıflandırma modelinin genel başarısına ve güvenilirliğine kritik düzeyde katkı sağlamaktadır. Gürültüden arındırılmış, zaman ekseninde eşitlenmiş ve genlikleri standartlaştırılmış olan bu temiz ses sinyalleri, bir sonraki aşamada Mel-Spektrogram görüntülerine dönüştürülürken patolojilere ait karakteristik yatay ve dikey frekans izlerinin çok daha belirgin bir biçimde ortaya çıkmasını sağlamaktadır. Bu izolasyon sayesinde, derin öğrenme modelinin ortam seslerini veya donanım bazlı farklılıkları ezberlemesinin önüne geçilmiş, ağır tamamen klinik olarak anlamlı olan "Crackle" ve "Wheeze" örüntülerine odaklanarak daha yüksek bir doğruluk ve genellenebilirlik kapasitesine ulaşması temin edilmiştir.

UYGULAMA AŞAMALARI VE KOD YAPISI

Bu bölümde proje kapsamında geliştirilen uygulamanın aşamaları ve kullanılan Python kodlarının işleyişi ayrıntılı olarak açıklanmaktadır. Solunum sesi verilerinin işlenmesinden başlayarak görüntü formatına dönüştürülmesi, veri setinin hazırlanması, derin öğrenme modellerinin eğitilmesi ve performanslarının değerlendirilmesine kadar gerçekleştirilen tüm işlemler ayrı kod dosyaları halinde geliştirilmiştir.

Proje modüler bir yapı benimsenerek tasarlanmış olup, her kod dosyası belirli bir görevi yerine getirecek şekilde hazırlanmıştır. Bu yaklaşım sayesinde veri ön işleme, veri dönüştürme, model eğitimi ve sonuç analizi süreçleri birbirinden bağımsız olarak yönetilebilmiş ve proje daha düzenli bir yapıya kavuşturulmuştur.

Aşağıdaki alt bölümlerde her bir kod dosyasının amacı, kullandığı yöntemler, gerçekleştirdiği işlemler ve proje içerisindeki rolü ayrıntılı olarak açıklanmaktadır. Böylece geliştirilen sistemin çalışma mantığı ve veri akışının tüm aşamaları sistematik bir şekilde ortaya konulmaktadır.

1. [ayarlar.py](#):

Genel Hedef: Bu dosya, solunum sesleri sınıflandırma projesinin "sinir merkezi" veya "yapılandırma yöneticisi" olarak görev yapmaktadır. Temel amaç; veri ön işleme, model eğitimi ve test gibi farklı aşamaların tamamında kullanılacak olan sabit değişkenleri, dosya yollarını ve hiperparametreleri tek bir merkezden yönetmektir. Bu modüler yaklaşım, "hardcoding" (değerleri doğrudan kod içine yazma) hatasını önler ve Transfer Learning/Fine-Tuning deneyleri sırasında parametre değişikliklerinin tüm projeye anında ve hatasız yansımaları sağlar.

Dosya İeriğinde Yapılan İşlemler ve Detaylar:

1. Rastgelelik Sabitleme (Reproducibility)

- Ne Yapıldı: `set_seed()` fonksiyonu ile Python'un yerleşik `random` kütüphanesi, `numpy` ve (eğer yüklüyse) `tensorflow` için başlangı çekirdek değeri (seed = 42) sabitlenmiştir. Ayrıca GPU işlemlerinin deterministik olmasını sağlayan ortam değışkenleri ayarlanmıştır.
- Ama: Akademik geçerlilik. Yapay zeka modelleri doğaları gereği stokastik (rastgele) süreçler içerir (ağırlıkların başlatılması, veri karıştırma vb.). Seed sabitlemesi, modelin farklı zamanlarda tekrar eğitildiğinde tamamen aynı sonuçları üretmesini garanti eder. Bu, model başarımlarının doğru bir şekilde kıyaslanabilmesi için kritik bir zorunluluktur.

2. Merkezi Dizin ve Dosya Yönetimi

- Ne Yapıldı: `os` modülü kullanılarak projenin ana dizini tespit edilmiş ve verisetleri (eğitim, doğrulama, test), dönüştürülmüş spektrogramlar, kaydedilecek modeller, ağırlıklar, grafikler ve loglar için standart yollar tanımlanmıştır.
- Ama: Projenin taşınabilirliğini artırmak. Kod, farklı bir işletim sisteminde (örneğin macOS) veya başka bir klasör dizininde çalıştırıldığında yol hataları (path errors) vermeyecektir. Veri akış hiyerarşisi net bir şekilde kurulmuştur.

3. Tıbbi Sinyal İşleme ve Mel-Spektrogram Dönüşümü

- Ne Yapıldı: Solunum seslerinin dijital işleme standartları belirlenmiştir. Hedef örnekleme frekansı (22050 Hz) ve kayıt süresi (5 saniye) sabitlenerek standart bir giriş boyutu oluşturulmuştur.
- Özellik Çıkarmı (Feature Extraction): Ses sinyallerini görsel verilere çevirecek olan Mel-Spektrogram algoritmalarının matematiksel sınırları çizilmiştir (`N_MELS=128`, `N_FFT=2048`, `HOP_LENGTH=512`). Filtreleme işlemi için frekans aralığı 50 Hz - 4000 Hz olarak ayarlanarak insan kulağının veya cihazın algıladığı dip gürültüler elenmiştir.
- Görüntü Boyutlandırma: `GORUNTU_BOYUTU = (224, 224)` ayarı ile oluşturulan spektrogramların, ImageNet mimarilerine (ResNet, MobileNet vb.) tam uyumlu hale getirilmesi hedeflenmiştir.

4. Transfer Öğrenmesi ve Model Hiperparametreleri

- Ne Yapıldı: Eğitim sürecinin dinamikleri tanımlanmıştır. Batch size (32), başlangı öğrenme oranı ($1e-3$) ve sınıflar (Normal, Crackle, Wheeze, Both) belirlenmiştir.
- Eğitim Stratejisi: Projenin merkezinde yer alan iki aşamalı eğitim stratejisi koda dökülmüştür:

- **EPOCHS_TRANSFER = 30**: Modelin sadece yeni eklenen sınıflandırıcı katmanlarının eğitileceği ilk aşama.
 - **EPOCHS_FINE_TUNE = 20** ve **LEARNING_RATE_FINE_TUNE = 1e-5**: Önceden eğitilmiş ağırlıkların (pre-trained weights) düşük bir öğrenme oranıyla yeni medikal veri setine hassas bir şekilde uyarlanacağı (fine-tuning) ikinci aşama.
2. veri_onisleme.py:
- Genel Hedef: Bu modül, "Tıbbi Sinyallerin Yapay Zeka ile Teşhisi" sürecinin ilk ve en temel adımıdır. Görevi; Kaggle üzerinden ham "Respiratory Sound Database" veri setini otonom olarak indirmek, medikal uzmanlar tarafından hazırlanan metin tabanlı anotasyon (işaretleme) dosyalarını okuyarak solunum döngülerini (respiratory cycles) ayırtmak ve derin öğrenme modellerinin güvenilirliğini sağlamak adına veri setini "Hasta Bazlı" (Patient-Level) olarak bölmektir. Çıktı olarak, sonraki adımlarda (spektrogram üretimi) kullanılacak olan yapılandırılmış bir metaveri (metadata) tablosu (**veri_metadata.csv**) üretir.

Uygulanan Temel İşlemler ve Metodoloji:

1. Veri Tedariği ve Otonom Ayırıştırma

- Ne Yapıldı: **kagglehub** kütüphanesi kullanılarak veri setinin indirilme süreci tamamen kod içine entegre edildi. Ardından **veri_seti_indir_ve_oku** fonksiyonu ile indirilen klasör ağacında gezinilerek (os.walk ve glob) tüm **.wav** (ses) ve onlara karşılık gelen **.txt** (anotasyon) dosyaları eşleştirildi.
- Amaç: Manuel indirme ve dosya taşıma hatalarını ortadan kaldırarak projeye tam bir otomasyon kazandırmak. Her bir **.txt** dosyasının içindeki başlangıç (**start**) ve bitiş (**end**) süreleri okunarak, uzun bir ses kaydının içindeki her bir nefes alıp-verme döngüsü bağımsız birer veri noktası olarak izole edilmiştir.

2. Çoklu Sınıf Etiketleme Mekanizması (Multi-Class Labeling)

- Ne Yapıldı: **etiket_belirle** fonksiyonu aracılığıyla, veri setindeki ikili (binary) anormallik göstergeleri olan "Crackle" (Çıtırtı) ve "Wheeze" (Hırıltı) değerleri 4 sınıflı bir yapıya dönüştürüldü:
 - 0 (Normal): Her iki anormallik de yok.
 - 1 (Crackle): Sadece çıtırtı var.
 - 2 (Wheeze): Sadece hırıltı var.
 - 3 (Both): Hem çıtırtı hem hırıltı aynı döngüde mevcut.
- Amaç: Modelin karar mekanizmasını basitleştirmek ve çok sınıflı sınıflandırma (Multi-Class Classification) problemine uygun bir zemin hazırlamak.

3. Hasta Bazlı Ayırım ve Veri Sızıntısını (Data Leakage) Önleme

- Ne Yapıldı: `hasta_bazli_ayrim` fonksiyonunda veri seti doğrudan döngü bazında (satır satır) değil, "Hasta ID" numaralarına göre kümelenerek bölündü. `train_test_split` kullanılarak hastalar rastgele ancak %70 Eğitim, %15 Doğrulama ve %15 Test setlerine dağıtıldı.
- Amaç ve Akademik Önemi: Bu adım, medikal yapay zeka projelerinin en kritik güvenlik önlemidir. Eğer veriler rastgele bölünseydi, "A" hastasının 1. solunum döngüsü Eğitim setinde, 2. solunum döngüsü ise Test setinde yer alabilirdi. Bu durumda model, hastalığın karakteristik sesini (Crackle/Wheeze) öğrenmek yerine, o spesifik hastanın göğüs kafesi rezonansını veya mikrofonun kayıt kalitesini ezberlerdi (Data Leakage - Veri Sızıntısı). Hasta bazlı ayırım yapılarak modelin daha önce hiç duymadığı hastalar üzerinde test edilmesi garanti altına alınmış, modelin gerçek dünya başarımı (generalization) güvenceye alınmıştır.

4. Veritabanı Yapılandırması (Metadata Export)

- Ne Yapıldı: Çıkarılan tüm özellikler (Hasta ID, dosya yolu, süreler ve atanan sınıflar) Pandas kütüphanesi yardımıyla bir `DataFrame` formatına dönüştürüldü ve `veri_metadata.csv` adıyla ana dizine kaydedildi.
- Amaç: İşlem yükü ağır olan veri okuma ve ayrıştırma işlemini bir kez yaparak sonuçları sabitlemek. Bu sayede `mel_spektrogram_uret.py` modülü, ses dosyalarını hangi saniyeler arasından keseceğini ve hangi klasöre kaydedeceğini doğrudan bu CSV dosyasından hatasız bir şekilde okuyabilmektedir.

3. veri_arttırma.py:

Genel Hedef: Bu modül, "Respiratory Sound Database" içerisindeki yapısal sınıf dengesizliğini (Class Imbalance) gidermek amacıyla tasarlanmıştır. Veri setinde 'Normal' (sağlıklı) solunum sesleri çoğunlukta iken, anormallik gösteren 'Wheeze' ve 'Both' (Crackle+Wheeze) sınıfları azınlıktadır. Modelin çoğunluk sınıfına aşırı uyum sağlamasını (Overfitting) ve azınlık sınıflarını göz ardı etmesini engellemek için, azınlık sınıflarına ait mevcut veriler sinyal işleme teknikleriyle manipüle edilerek tamamen sentetik ancak gerçeğe uygun yeni veri noktaları (Oversampling) üretilmiştir.

Uygulanan Temel İşlemler ve Metodoloji:

1. Veri Sızıntısına Karşı Katı İzolasyon (Split Isolation)

- Ne Yapıldı: Pandas ile okunan `veri_metadata.csv` dosyası üzerinden sadece `split == 'train'` (Eğitim) etiketine sahip hastalar filtreye dahil edilmiştir. Doğrulama (Validation) ve Test setleri bu işlemin tamamen dışında tutulmuştur.
- Amaç ve Gerekçe: Sentetik olarak üretilmiş, değiştirilmiş seslerin modelin test aşamasına sızması, modelin gerçek dünya başarımını yanıltıcı derecede yüksek gösterebilir. Sadece eğitim setinin dengelenmesi, modelin öğrenme

aşamasında tüm hastalıklara eşit ağırlık vermesini sağlarken, değerlendirme aşamasında %100 orijinal ve klinik verilerle sınanmasını garanti altına alır.

2. İşitsel Sinyal Manipülasyon Teknikleri (Audio Augmentation)

- Ne Yapıldı: **librosa** kütüphanesi ve **numpy** kullanılarak, rastgele seçilen azınlık sınıfı seslerine aşağıdaki üç farklı dijital bozulma varyasyonundan biri uygulandı:
 - Time Stretching (Zaman Esnetme): Ses sinyalinin tonu (pitch) bozulmadan çalma hızı %80 ile %120 aralığında rastgele değiştirildi. Bu işlem, farklı hastaların nefes alıp verme ritimlerindeki ve akciğer kapasitelerindeki doğal değişkenliği simüle eder.
 - Pitch Shifting (Ton Kaydırma): Sinyalin çalma hızı sabit tutularak frekans değerleri rastgele -2 ile +2 adım (steps) kaydırıldı. Bu sayede, aynı solunum anormalliğinin farklı rezonanslarda veya göğüs kafesi yapılarında nasıl duyulabileceği modellenmiştir.
 - Gaussian Noise (Gauss Gürültüsü Ekleme): Ham sinyalin üzerine matematiksel olarak rastgele beyaz gürültü eklendi. Bu teknik, klinik ortamlardaki arka plan seslerini, stetoskopun hastanın cildine sürtünmesinden kaynaklanan parazitleri veya düşük kaliteli mikrofon kayıtlarını taklit ederek modelin dış gürültülere karşı dayanıklılığını (robustness) artırır.

3. Otomatik Dengeleme (Oversampling) ve Görüntü Entegrasyonu

- Ne Yapıldı: **veri_dengeleme_islemi** fonksiyonunda eğitim setindeki en büyük sınıfa ait örnek sayısı (genellikle 'Normal' sınıfı) tavan değer olarak belirlendi. Diğer eksik sınıflar için bu tavan değere ulaşılan kadar (eksik sayı kadar) bir döngü başlatıldı. Rastgele seçilen orijinal sinyaller filtrelendi, augmentasyon uygulandı, süresi **uzunluk_sabit** ile standartlaştırıldı ve **mel_spektrogram_uret.py** içindeki ana fonksiyon çağrılarak doğrudan Mel-Spektrogram görsellerine dönüştürülüp eğitim klasörüne ("aug_..." ön ekiyle) kaydedildi.
- Amaç: Makine öğrenmesi algoritmalarının maliyet fonksiyonlarını (Loss Functions) optimize ederken sınıf frekanslarından etkilenmesini engellemek. Görüntü dönüşümünün de aynı script içinde otomatik yapılması, disk üzerinde gereksiz yere ekstra **.wav** dosyaları tutulmasının önüne geçerek depolama optimizasyonu sağlamıştır.

4. **mel_spektrogram_uret.py**:

Genel Hedef: Bu modül, ham solunum sesi verilerini (audio signals) Derin Öğrenme (Deep Learning) modellerinin anlayabileceği yapılandırılmış görsel formatlara dönüştürmekten sorumludur. **veri_metadata.csv** içerisindeki yönergeleri takip ederek her bir solunum döngüsünü bağımsız olarak keser, sinyal işleme teknikleriyle temizler ve Keras'ın **image_dataset_from_directory**

fonksiyonuna tam uyumlu olacak şekilde hiyerarşik bir klasör yapısında (Train/Val/Test) sınıflandırarak kaydeder.

Uygulanan Temel İşlemler ve Metodoloji:

1. Sinyal İşleme ve Gürültü Filtreleme (Noise Reduction)

- Ne Yapıldı: `gurultu_temizle` fonksiyonu içerisinde *Butterworth Bandpass (Bant Geçiren)* filtresi uygulandı. `ayarlar.py` dosyasında belirlenen 50 Hz (alt sınır) ve 4000 Hz (üst sınır) aralığı kullanılarak Nyquist frekansına göre kesim noktaları belirlendi.
- Amaç ve Gerekçe: Klinik ortamlarda alınan steteskop kayıtları kalp atışları (düşük frekanslı mekanik gürültü), hastanın hareketi veya ortamdaki yüksek frekanslı sesler gibi parazitler barındırır. Solunum anormalliklerinin (Crackle, Wheeze) karakteristik frekansları bu filtrelenen aralıkta yer aldığından, modelin yanıltıcı özellikleri (noise) öğrenmesi matematiksel olarak engellenmiştir.

2. Veri Standardizasyonu (Padding ve Trimming)

- Ne Yapıldı: `uzunluk_sabitler` fonksiyonu ile her bir ses döngüsünün vektörel uzunluğu `MAX_SES_UZUNLUGU` değerine sabitlendi. Kısa sinyallerin sonuna sıfır (zero-padding) eklendi, uzun sinyaller ise kesildi.
- Amaç ve Gerekçe: Sinir ağları, matris çarpımları yapabilmek için giriş tensörlerinin (tensor) sabit bir boyutta olmasını zorunlu kılar. Bu adım, spektrogram matrislerinin yatay ekseninde (zaman eksenini) birebir aynı boyutta üretilmesini garanti eder.

3. Mel-Spektrogram Dönüşümü ve Görüntü Optimizasyonu

- Ne Yapıldı: `spektrogram_olustur_ve_kaydet` fonksiyonu projenin kalbini oluşturur. Sinyaller sırasıyla şu matematiksel dönüşümlerden geçirilmiştir:
 - Hızlı Fourier Dönüşümü (STFT): Sinyalin frekans bileşenleri zaman ekseninde çıkarıldı.
 - Mel Ölçeği Uygulaması: Frekans eksenini, insan kulağının veya medikal cihazların logaritmik duyarlılığına uygun olan Mel ölçeğine (`N_MELS=128`) dönüştürüldü.
 - Logaritmik Genlik (dB): Enerji değerleri Desibel (dB) ölçeğine çevrilerek zayıf solunum seslerinin belirginliği artırıldı.
 - Min-Max Optimizasyonu ve Renklendirme: Matris değerleri 0-255 aralığına normalize edildi ve OpenCV'nin `cv2.COLORMAP_JET` filtresiyle 3 kanallı RGB görsellere dönüştürüldü.
- Amaç ve Gerekçe: Önceden ImageNet üzerinde eğitilmiş Transfer Learning mimarileri (ResNet, MobileNet vb.) 3 kanallı (RGB) ve standart boyutlu (224x224) girişler bekler. Gri tonlamalı spektrogramları ısı haritasına (JET)

çevirmek, pikseller arasındaki kontrastı artırarak evrişim katmanlarının (convolutional layers) solunum anomalilerindeki örüntüleri (örneğin hırıltıların yatay çizgileri veya çıtırtıların dikey patlamaları) daha kolay tespit etmesini sağlar. Ayrıca `cv2.flip` işlemiyle düşük frekansların resmin alt kısmına hizalanması, medikal literatürdeki standart spektrogram gösterimiyle uyumlu hale getirilmiştir.

4. Veri Tabanı Hiyerarşisinin İnşası

- Ne Yapıldı: `islem_baslat` döngüsü içinde Pandas kütüphanesi ile meta veriler okunarak, her bir spektrogram ilgili `hasta_id` ve döngü indeksi ile etiketlendi. Veriler Eğitim (Train), Doğrulama (Val) ve Test klasörlerindeki ilgili hastalık (Normal, Crackle, Wheeze, Both) alt klasörlerine `tqdm` ilerleme çubuğu eşliğinde aktarıldı.
- Amaç: Makine öğrenmesi hattının (pipeline) veri sızıntısı (data leakage) olmadan, Keras veri yükleyicileriyle tam entegre bir şekilde çalışmasını sağlayan donanımsal zemin hazırlanmıştır. İstisnai durumlarda (bozuk ses dosyaları) `try-except` bloğu ile sürecin çökmesi engellenerek otomasyonun sürekliliği sağlanmıştır.

5. `model_egitimi.py`:

Genel Hedef: Bu modül, bir önceki aşamada üretilen 2 boyutlu Mel-Spektrogram görüntülerini girdi olarak alarak, solunum anormalliklerini (Crackle, Wheeze) tespit etmek üzere derin öğrenme modellerini eğitir. Projenin karşılaştırmalı yapısına uygun olarak, önceden ImageNet veri seti üzerinde eğitilmiş (pre-trained) üç farklı Evrişimli Sinir Ağı (CNN) mimarisi seçilmiş ve "Transfer Öğrenmesi" (Transfer Learning) metodolojisiyle tıp alanına uyarlanmıştır.

Uygulanan Temel İşlemler ve Metodoloji:

1. Sistem Optimizasyonu ve Veri Yükleme (Data Pipeline)

- macOS SSL Entegrasyonu: Geliştirme ortamı olarak macOS kullanıldığında ImageNet ağırlıklarının indirilmesi sırasında karşılaşılan sertifika (CERTIFICATE_VERIFY_FAILED) hataları, `ssl._create_unverified_context` direktifi ile aşılmış ve sistemin kesintisiz çalışması güvence altına alınmıştır.
- Bellek ve İşlemci Yönetimi: `veri_yukleyicileri_olustur` fonksiyonunda Keras'ın `image_dataset_from_directory` metodu kullanılarak veriler RAM'i boğmadan batch'ler (32'li paketler) halinde çekilmiştir. Özellikle `cache()` ve `prefetch(tf.data.AUTOTUNE)` fonksiyonları kullanılarak veri okuma hızı maksimize edilmiş, GPU'nun (veya işlemcinin) veri beklerken boşa kalması (bottleneck) engellenmiştir.

2. Transfer Öğrenmesi (Transfer Learning) ve Mimari Tasarım

- Karşılaştırmalı Modeller: Projede performans kıyası yapabilmek için üç farklı mimari tercih edilmiştir:
 - MobileNetV2: Düşük parametre sayısı ile hızlı çalışan, gelecekte edge (uç) cihazlara veya mobil platformlara entegre edilebilecek hafif mimari.
 - DenseNet121: Katmanlar arası yoğun bağlantıları (dense connections) sayesinde kaybolmaya yüz tutan ince özelliklerin (Wheeze gibi tiz frekanslı seslerin) derin katmanlara taşınmasını sağlayan güçlü mimari.
 - Xception: Derinlik ayrıştırılabilir evrişimler (Depthwise Separable Convolution) kullanarak geniş özellik çıkarımı yapan mimari.
- Sınıflandırıcı Kafa (Classification Head) İnşası: `model_olustur` fonksiyonunda, seçilen temel modellerin ağırlıkları dondurulmuş (`trainable = False`), böylece alt katmanlardaki temel şekil ve doku tanıma yetenekleri korunmuştur. Modelin çıkışına yeni bir "öğrenme kafası" eklenmiştir:
 - Boyut indirgeme için `GlobalAveragePooling2D`.
 - Ezberlemeyi (Overfitting) engellemek ve ağırlık dağılımını dengelemek için `BatchNormalization` ve `Dropout` (sırasıyla %50 ve %30 oranlarında) katmanları.
 - Sınıflandırma yeteneği kazanması için 256 nöronlu `Dense` (ReLU) ve nihai karar mekanizması olan 4 nöronlu (Normal, Crackle, Wheeze, Both) `Dense` (Softmax) katmanı eklenmiştir.

3. Otonom Eğitim Döngüsü ve Hata Toleransı

- Kaldığı Yerden Devam Etme (Fault-Tolerance): `egitim_baslat` fonksiyonunda sistem çökmesine veya manuel durdurmalara karşı bir koruma mekanizması (checkpointing) kurulmuştur. Model, eğitime başlamadan önce `latest.h5` dosyasını ve `base_history.csv` loglarını kontrol ederek, yarım kalmış bir eğitim varsa en son epoch'tan otomatik olarak devam edecek şekilde kodlanmıştır.
- Dinamik Geri Çağrılar (Callbacks): Eğitim süreci tamamen otonom hale getirilmiştir:
 - ModelCheckpoint: Yalnızca doğrulama kaybının (val_loss) en düşük olduğu "en iyi" ağırlıkları kaydeder.
 - EarlyStopping: Model 7 epoch boyunca gelişim göstermezse eğitimi erkenden keserek zaman ve enerji tasarrufu sağlar.
 - ReduceLROnPlateau: Model yerel bir minimuma (local minima) takıldığında, öğrenme oranını (learning rate) yarı yarıya düşürerek daha hassas bir optimizasyon yapar.
 - TensorBoard & CSVLogger: Eğitim süreci boyunca tüm kayıp ve doğruluk metriklerini anlık olarak kaydeder, bu veriler raporun sonuç bölümündeki grafikler için hayati önem taşır.

6. `ince_ayar.py`:

Genel Hedef: Bu modül, `model_egitimi.py` dosyasında gerçekleştirilen Transfer Öğrenmesi (Transfer Learning) aşamasının doğal bir devamı niteliğindedir. İlk aşamada ImageNet veri setiyle öğrenilmiş temel ağırlıklar

(köşe, kenar, renk tanıma vb.) korunarak sadece modelin en sonuna eklenen sınıflandırıcı katman eğitilmişti. Bu "İnce Ayar" modülünde ise amaç, modelin üst katmanlarının kilitlerini açarak evrişim ağlarının (CNN) doğrudan tıbbi spektrogramların karakteristik yapılarını (örneğin; hırıltıların yatay frekans çizgilerini veya çıtırtıların dikey enerji patlamalarını) spesifik olarak öğrenmesini sağlamaktır.

Uygulanan Temel İşlemler ve Metodoloji:

1. Katman Kilidi Açma Stratejisi (Partial Unfreezing)

- Ne Yapıldı: `ince_ayar_uygula` fonksiyonu içerisinde öncelikle daha önceden eğitilmiş temel modeller (`_base.h5`) diskten belleğe yüklendi. Modelin tüm katmanları kısa bir süreliğine eğitime açıldıktan sonra, sadece ağın son 30 katmanı (`FINE_TUNE_KATMAN_SAYISI = 30`) eğitilebilir durumda bırakılarak geri kalan alt katmanlar tekrar donduruldu.
- Amaç ve Gerekçe: Modelin ilk katmanları genellikle evrensel özellikleri (çizgiler, renk geçişleri) çıkarır, son katmanlar ise probleme özgü spesifik örüntüleri algılar. Sadece son 30 katmanın kilidinin açılması, modelin genel geçer görüntü işleme yeteneğini kaybetmeden, medikal ses verilerine ait ince detaylara adapte olmasını (domain adaptation) sağlar.

2. Katastrofik Unutmayı Önleme (Preventing Catastrophic Forgetting)

- Ne Yapıldı: Kilidi açılan katmanlar, `ayarlar.py` dosyasından çekilen çok düşük bir öğrenme oranı (`LEARNING_RATE_FINE_TUNE = 1e-5`) kullanılarak Adam optimizasyon algoritması ile yeniden derlendi.
- Amaç ve Gerekçe: Bu adım projenin başarısı için kritik öneme sahiptir. Eğer fine-tuning aşamasında yüksek bir öğrenme oranı kullanılsaydı, gradyan güncellemeleri çok sert olacak ve modelin ImageNet'ten taşıdığı, milyonlarca görselle kazandığı o değerli ön bilgi kalıcı olarak silinecekti (Yapay Sinir Ağları literatüründe buna *Catastrophic Forgetting* - *Katastrofik Unutma* denir). Öğrenme oranının mikro seviyelere çekilmesi, ağırlıklarda sadece çok küçük ve hassas oynamalar yapılmasını garanti altına almıştır.

3. Dinamik Eğitim Gözetimi ve Kayıt Altına Alma

- Ne Yapıldı: Eğitim sırasında aşırı ezberlemeyi (overfitting) ve gereksiz zaman kaybını önlemek için sıkı bir Callback (Geri çağırma) mekanizması kuruldu:
 - EarlyStopping: Doğrulama kaybında (`val_loss`) 5 epoch boyunca iyileşme olmazsa eğitim durdurulup en iyi ağırlıklar geri yüklendi (`patience=5`).
 - ReduceLROnPlateau: Model öğrenmede durgunluk yaşarsa, zaten düşük olan öğrenme oranı yarı yarıya düşürülerek mikroskobik optimizasyona geçildi (`min_lr=1e-7`).

- Kayıt Sistemi: Her bir mimarinin (MobileNetV2, DenseNet121, Xception) eğitim geçmişi (Accuracy ve Loss değerleri), raporun sonuç bölümünde görselleştirilmek üzere `_finetune_history.csv` formatında diskteki loglar dizinine aktarıldı. Modelin nihai en iyi hali ise `_finetuned.h5` olarak kaydedilerek test veya canlı kullanım aşamasına hazır hale getirildi.
- 7. performans_analizi.py:
Genel Hedef: Bu modülün temel amacı, Transfer Learning ve Fine-Tuning süreçlerinden geçerek eğitilmiş modellerin (MobileNetV2, DenseNet121, Xception) gerçek dünya başarımını ölçmektir. Bunu yaparken, modelin eğitim ve doğrulama aşamalarında hiçbir şekilde görmediği "Test" veri seti kullanılır. Elde edilen tüm istatistiksel sonuçlar, projenin nihai başarısını kanıtlamak üzere yapılandırılmış metin (.txt) ve tablo (.csv) formatlarında dışa aktarılır.

Uygulanan Temel İşlemler ve Metodoloji:

1. Test Verisinin Güvenli ve Sıralı Yüklenmesi

- Ne Yapıldı: `test_verisini_yukle` fonksiyonunda Keras'ın veri yükleyicisi çağrılırken çok kritik bir parametre olan `shuffle=False` (karıştırmayı kapat) ayarı kullanılmıştır.
- Amaç ve Gerekçe: Eğitim sırasında verilerin karıştırılması modelin ezberlemesini önlerken, test aşamasında karıştırma işleminin yapılması tahmin edilen etiketler (predictions) ile gerçek etiketlerin (ground truth) eşleşmesini bozar. Bu ayarın kapalı tutulması, her bir ses döngüsü için yapılan yapay zeka tahmininin doğru hastaya ve doğru anormallik kaydına birebir karşılık gelmesini matematiksel olarak garanti altına almıştır.

2. Çok Boyutlu İstatistiksel Metriklerin Hesaplanması

- Ne Yapıldı: `metrikleri_hesapla` fonksiyonu içerisinde `Scikit-Learn` kütüphanesinin fonksiyonları kullanılarak sadece Doğruluk (Accuracy) değil; Kesinlik (Precision), Duyarlılık (Recall), F1-Skoru ve ROC-AUC (Alıcı İşletim Karakteristiği - Eğri Altında Kalan Alan) metrikleri de "weighted" (ağırlıklı) ortalama ile hesaplanmıştır.
- Amaç ve Akademik Önemi: Tıbbi teşhis projelerinde sadece Doğruluk (Accuracy) oranına bakmak yanıltıcıdır. Örneğin model, çoğunluk sınıfı olan "Normal" vakaları harika biliyor ancak "Wheeze" vakalarını kaçırıyorsa genel doğruluk yüksek çıksa bile klinik açıdan model başarısızdır.
 - Precision ve Recall: Modelin hırıltı/çıtırtı anormalliklerini ne kadar hassas yakaladığını gösterir.
 - F1-Score: Dengesiz veri setleri için en güvenilir metrik olan F1, kesinlik ve duyarlılığın harmonik ortalamasını sunar.
 - ROC-AUC (`multi_class='ovr'`): Modelin sınıfları birbirinden ayırt etme gücünü, OVR (One-vs-Rest / Bire Karşı Diğerleri) stratejisiyle çok sınıflı yapıya uygun şekilde puanlar.

3. Otonom Karşılaştırmalı Analiz ve Çıktı Üretimi

- Ne Yapıldı: `analiz_yap` fonksiyonu, kaydedilmiş olan en iyi fine-tune ağırlıklarını (`_finetuned.h5`) diskten sırayla çeker. Her model için `model.predict()` ile test seti üzerinde tahminleme (inference) yapar.
- Çıktı Formatları: * `detayli_analiz_raporu.txt`: Her bir hastalık sınıfının (Normal, Crackle, Wheeze, Both) kendi içindeki performansını gösteren detaylı bir metin raporu oluşturur.
 - `model_performans_karsilastirmasi.csv`: Üç modelin (MobileNetV2, DenseNet121, Xception) genel metriklerini yan yana koyarak, hangi mimarinin bu tıbbi sinyal analizinde en iyi sonucu verdiğini saniyeler içinde gösteren bir Excel/CSV tablosu üretir.

8. grafik_uretimi.py:

Genel Hedef: Bu modül, modelin öğrenme sürecini (eğitim logları) ve saha başarımını (test tahminleri) `matplotlib` ve `seaborn` kütüphanelerini kullanarak akademik kalite standartlarında grafiklere dönüştürür. Üretilen tüm görseller yüksek çözünürlüklü (300 DPI) olarak kaydedilir ve projenin savunma sunumunda veya nihai raporunda projenin başarısını kanıtlayacak temel argümanları oluşturur.

Uygulanan Temel İşlemler ve Metodoloji:

1. Eğitim Sürecinin Kesintisiz Görselleştirilmesi (Learning Curves)

- Ne Yapıldı: `egitim_grafiklerini_ciz` fonksiyonunda, `model_egitimi.py` (Transfer Learning) ve `ince_ayar.py` (Fine-Tuning) aşamalarında kaydedilen iki farklı CSV log dosyası (history) birleştirildi.
- Amaç ve Akademik Önemi: Modelin öğrenme (Accuracy) ve hata (Loss) eğrileri tek bir grafik üzerinde çizdirildi. Grafiğin ortasına yerleştirilen "Kırmızı Kesik Çizgi", base model eğitiminin nerede bittiğini ve ince ayar (fine-tuning) aşamasının nerede başladığını gösterir. Bu görsel, düşük öğrenme oranıyla ($1e-5$) yapılan ince ayar müdahalesinin, modelin doğruluk oranını nasıl yukarı taşıdığını ve hatayı nasıl stabilize ettiğini jüriye somut olarak kanıtlamak için tasarlanmıştır.

2. Hata Analizi ve Karmaşıklık Matrisi (Confusion Matrix)

- Ne Yapıldı: `metrik_grafiklerini_ciz` fonksiyonunun ilk aşamasında, modelin test setindeki tahminleri ile gerçek hasta verileri karşılaştırılarak bir Isı Haritası (Heatmap) oluşturuldu.
- Amaç ve Gerekçe: Tıbbi yapay zeka projelerinde modelin "neyi doğru bildiğinden" ziyade "neyi neyle karıştırdığını" görmek hayati önem taşır. Örneğin; model "Normal" bir hastaya yanlışlıkla "Wheeze" diyebilir (False Positive - Yanlış Alarm) veya çok daha tehlikelisi, "Crackle" olan bir hastaya "Normal" diyebilir (False Negative - Hastalığı Kaçırma). Karmaşıklık matrisi,

modelin zayıf noktalarını (örneğin hırıltı ve çıtırtı seslerini birbirine ne kadar karıştırdığını) şeffaf bir şekilde ortaya koyar.

3. Sınıf Ayrım Gücü: ROC Eğrisi (Receiver Operating Characteristic)

- Ne Yapıldı: Aynı fonksiyonun ikinci aşamasında, çok sınıflı (Multi-class One-vs-Rest) yapıya uygun olarak her bir hastalık sınıfı için (Normal, Crackle, Wheeze, Both) ayrı bir ROC eğrisi çizdirildi ve Eğri Altında Kalan Alan (AUC) değerleri hesaplandı.
- Amaç: ROC eğrisinin sol üst köşeye ne kadar yakın olduğu, modelin sınıfları birbirinden ayırma gücünü gösterir. Grafikteki siyah kesik çizgi rastgele tahmini (%50 başarı) temsil ederken, modelin eğrileri bu çizginin ne kadar üzerindeyse projenin klinik geçerliliği o kadar yüksektir.

4. Veri Seti Dağılım Anatomisi (Data Distribution)

- Ne Yapıldı: [sinif_dagilimi_ciz](#) fonksiyonu kullanılarak projenin başında oluşturulan [veri_metadata.csv](#) dosyası analiz edildi.
- Amaç: Raporun "Veri Seti" bölümünde kullanılmak üzere iki temel görsel üretildi. Bar Chart (Çubuk Grafik) verilerin Eğitim/Doğrulama/Test setlerine nasıl dengeli dağıtıldığını gösterirken; Pie Chart (Pasta Grafik) "Normal" solunum seslerinin veritabanını ne kadar domine ettiğini görselleştirir. Bu pasta grafik, daha önce yaptığın "Veri Artırma" (Data Augmentation) işleminin ne kadar zorunlu ve haklı bir hamle olduğunu savunmak için kullanılacak temel kanıttır.

5. Açıklanabilir Yapay Zeka (XAI) Altyapısı

- Not: Modül içerisinde yer alan [grad_cam_olustur](#) fonksiyonu, modelin spektrogram üzerinde hangi piksellere (hangi frekans aralıklarına) odaklanarak "Hastalık var" kararı verdiğini gösterecek olan Isı Haritalarının temelini belirtir. Bu yapı, gelecekte projenin "Black Box" (Kara Kutu) algısını kırmak için geliştirilebilecek potansiyel bir modül olarak projede yerini almıştır.

9. [tahmin.py](#):

Genel Hedef: Bu modül, dışarıdan sisteme beslenen tamamen yeni ve bağımsız ham bir solunum sesini ([.wav](#)) analiz etmek üzere tasarlanmış uçtan uca (end-to-end) bir tahmin mekanizmasıdır. Eğitim sürecinde kullanılan tüm veri ön işleme (preprocessing) adımlarını otonom olarak simüle eder, daha önceden eğitilip diske kaydedilmiş derin öğrenme modellerini ([_finetuned.h5](#)) belleğe yükler ve hekimlerin yorumlayabileceği formatta yüzdelik ihtimaller barındıran klinik bir karar çıkarır.

Uygulanan Temel İşlemler ve Metodoloji:

1. Veri Hattının (Data Pipeline) Simülasyonu

- Ne Yapıldı: `sesi_spektrograma_cevir` fonksiyonu ile, verilen ham ses dosyası öncelikle Butterworth filtresinden (50Hz - 4000Hz) geçirilerek gürültüden arındırılır ve uzunluğu standart `MAX_SES_UZUNLUGU` değerine sabitlenir. Ardından Mel-Spektrogram dönüşümü, dB normalizasyonu ve OpenCV ile 224x224 RGB (JET Colormap) formatına dönüştürme işlemleri sırasıyla uygulanır.
- Amaç ve Akademik Önemi: Makine öğrenmesinde "Eğitim ve Tahmin Uyumsuzluğu" (Train-Serving Skew) en sık karşılaşılan hatalardan biridir. Modelin canlı ortamda doğru çalışabilmesi için, giriş verisinin eğitim aşamasındaki veriyle birebir aynı matematiksel işlemlerden (aynı örnekleme oranı, aynı Fourier pencereleme boyutları) geçmesi zorunludur. Ayrıca `np.expand_dims` fonksiyonu kullanılarak 3 boyutlu resim tensörü, Keras mimarilerinin beklediği 4 boyutlu "Batch" (1, 224, 224, 3) formuna getirilerek sisteme uyarlanmıştır.

2. Dinamik Model Yönetimi ve Karar Mekanizması

- Ne Yapıldı: `tahmin_yap` fonksiyonu, parametrik olarak aldığı modele (varsayılan olarak literatürdeki güçlü mimarilerden olan DenseNet121) spektrogramı gönderir. `model.predict()` üzerinden çıkan dizi, ağın sonundaki *Softmax* katmanının ürettiği 0 ile 1 arasındaki değerlerdir. Bu değerler 100 ile çarpılarak yüzdelik dilimlere dönüştürülür ve `np.argmax` ile en yüksek olasılığa sahip sınıf "Nihai Karar" olarak ekrana basılır.
- Amaç: Çıktıyı sadece "Crackle" veya "Normal" diyerek kesip atmamak, arkasındaki matematiksel güven skorunu (Confidence Score) da göstererek medikal bir asistan/ikinci görüş yazılımı konseptine uygun, şeffaf bir raporlama sunmak.

3. Komut Satırı Arayüzü (CLI) Entegrasyonu

- Ne Yapıldı: Python'un `sys.argv` modülü entegre edilerek, scriptin terminal veya komut istemcisi üzerinden dışarıdan argüman alarak (Örn: `python tahmin.py ornek_ses.wav MobileNetV2`) çalıştırılması sağlandı.
- Amaç: Bu scriptin sadece statik bir kod bloğu değil, dinamik ve esnek bir sistem aracı (Executable Tool) haline getirilmesi. Bu modüler yapı sayesinde, gelecekte bu yapay zeka çekirdeğinin önüne bir Web arayüzü (Streamlit/Flask) veya Masaüstü uygulaması entegre edilmek istendiğinde, backend (arka plan) mekanizması halihazırda sorunsuz çalışmaya hazırdır.

Transfer Learning ve Fine-Tuning Yaklaşımı

1. Transfer Öğrenmesi (Transfer Learning) ve Tıbbi Sinyal İşlemedeki Kavramsal Temelleri

Derin öğrenme modellerinin sıfırdan eğitilmesi, optimizasyon süreçlerinde milyonlarca parametrenin rastgele ağırlıklarla başlatılmasını ve bu ağırlıkların hedef veri kümesi üzerinden geriye yayılım (*backpropagation*) algoritmasıyla optimize edilmesini gerektirir. Ancak bu geleneksel yaklaşım, özellikle veri tedarikinin kısıtlı veya maliyetli olduğu alanlarda ciddi başarımla zafiyetlerine yol açmaktadır. Bu kısıtlamayı aşmak amacıyla geliştirilen Transfer Öğrenmesi (*Transfer Learning*), bir kaynak görevde (*source task*) elde edilen bilgi ve öznitelik haritalarının, benzer veya tamamen farklı bir hedef göreve (*target task*) aktarılması felsefesine dayanmaktadır. Çalışma prensibi açısından evrişimli sinir ağlarının (*CNN*) hiyerarşik yapısından yararlanır. Bir ağın ilk katmanları çizgiler, kenarlar, köşeler ve renk geçişleri gibi evrensel ve düşük seviyeli (*low-level*) öznitelikleri öğrenirken; derin katmanlara inildikçe modele özgü soyut ve yüksek seviyeli (*high-level*) geometrik yapılar çözülür. Transfer öğrenmesi, milyonlarca genel görüntü içeren ImageNet gibi devasa veri kümeleri üzerinde eğitilmiş popüler mimarilerin bu evrensel özellik çıkarma kapasitesini doğrudan hedef probleme miras bırakarak derin öğrenme literatüründe devrimsel bir optimizasyon kolaylığı sağlamaktadır.

2. İnce Ayar (Fine-Tuning) Mekanizması ve Matematiksel Mantiği

Transfer öğrenmesi sürecinde, önceden eğitilmiş temel modelin evrişimli katmanları genellikle dondurulur ve ağın sonuna eklenen yeni sınıflandırma kafası (*classification head*) eğitilir. Bu durum, modelin kaynak alandan getirdiği öznitelik çıkarma yeteneğini aynen korumasını sağlar. Ancak hedef veri kümesinin kendine has karakteristik dokusal özellikleri, genel nesne tanıma özniteliklerinden farklılaştığında sadece son katmanları eğitmek maksimum başarıma ulaşmak için yetersiz kalmaktadır. Bu noktada devreye giren İnce Ayar (*Fine-Tuning*), dondurulmuş olan temel katmanların belirli bir kısmının veya tamamının kilitlerinin açılarak hedef veri kümesine özel olarak yeniden optimize edilmesi işlemidir.

İnce ayar aşamasının matematiksel ve stratejik olarak transfer öğrenmesinden en büyük farkı, katmanların ağırlık matrislerinde mikroskobik düzeyde güncellemeler yapılmasıdır. Bu süreçte öğrenme oranının (*learning rate*) transfer öğrenmesi aşamasına kıyasla çok daha düşük bir seviyeye (örneğin 10⁻³'ten 10⁻⁵'e) çekilmesi akademik bir zorunluluktur. Eğer yüksek bir öğrenme oranı kullanılırsa, sert gradyan güncellemeleri nedeniyle modelin ImageNet gibi devasa bir veri tabanından kazandığı evrensel ve değerli ön bilgiler kalıcı olarak silinir. Yapay sinir ağları literatüründe Katastrofik Unutma (*Catastrophic Forgetting*) olarak adlandırılan bu risk, öğrenme oranının mikro seviyelere düşürülmesiyle engellenir. Böylece model, ağırlık yapılarını kökten değiştirmeden, yeni hedef verinin ince akustik ve görsel detaylarına göre milimetrik olarak yeniden hizalar (*domain adaptation*).

3. Sınırlı Medikal Veri Kümesi Kısıtları Altında Yaklaşımın Tercih Edilme Gerekçeleri

Bu projede transfer öğrenmesi ve ince ayar yaklaşımlarının bir arada kullanılmasının temel gerekçesi, *ICBHI Respiratory Sound Database* veri setinin tıbbi doğasından

kaynaklanan yapısal kısıtlılıkları ve sınıf dengesizlikleridir. Klinik ortamlardan toplanan solunum sesleri, doğası gereği hem sınırlı sayıda hastadan elde edilebilir hem de medikal uzmanlar tarafından her bir nefes döngüsünün manuel etiketlenmesini gerektiren zorlu bir süreç barındırır. Bu çalışmada ham akustik veriler dijital sinyal işleme adımlarından geçirilerek iki boyutlu Mel-Spektrogram görüntülerine dönüştürülmüştür. Elde edilen 2B görüntüler, pikseller üzerinden hırıltı ve çıtırtı gibi patolojik desenleri temsil etse de, sıfırdan eğitilecek milyonlarca parametreye sahip derin CNN modelleri için mutlak örnek sayısı bağlamında yetersiz kalmaktadır.

Eğer bu kısıtlı medikal veri kümesiyle MobileNetV2, DenseNet121 veya Xception gibi derin mimariler sıfırdan eğitime çalışılıyorsa, ağlar çok yüksek ihtimalle eğitim verilerini tamamen ezberleyecek ve aşırı öğrenme (*overfitting*) tuzağına düşecekti. Tıbbi yapay zeka projelerinde *overfitting*, modelin eğitim esnasında yüksek doğruluk oranları sunmasına karşın klinik sahada daha önce hiç karşılaşmadığı yeni hastalarda tamamen başarısız tahminler üretmesi anlamına gelir ki bu durum tıbbi teşhis yazılımlarında kabul edilemez bir zafiyettir. Transfer öğrenmesi, modelin parametre alanını daha yolun başında mantıklı ve optimize edilmiş bir koordinata yerleştirerek küçük veri setlerinde bile kararlı ve güvenilir bir öğrenme zemini inşa etmektedir.

4. Yöntemin Sağladığı Hesaplamalı ve Performans Odaklı Avantajlar

Kurgulanan iki aşamalı eğitim stratejisi, projeye hem donanımsal hem de istatistiksel açıdan çok yönlü avantajlar sağlamaktadır. İlk olarak, ağırlıkların büyük bölümünün dondurulması, geriye yayılım algoritması esnasında türev hesaplaması yapılacak parametre sayısını dramatik şekilde azalttığından çok daha kısa bir eğitim süresi ortaya çıkarmaktadır. Bu durum, yüksek hesaplama maliyetlerini ortadan kaldırarak projenin standart donanımlarda veya kısıtlı CPU/GPU birimlerine sahip geliştirme ortamlarında bile dakikalar içerisinde optimize edilebilmesine olanak tanır.

Performans odaklı bakıldığında ise transfer öğrenmesi entegrasyonu, sıfırdan eğitime kıyasla çok daha yüksek doğruluk (*Accuracy*) ve Eğri Altında Kalan Alan (*AUC*) skorlarına ulaşılmasını tetikler. Model, sıfırdan eğitilen bir ağın yerel minimumlara (*local minima*) takılma veya gradyan patlaması/kaybolması yaşama risklerini tamamen ekarte eder. Önceden öğrenilmiş görsel hiyerarşinin yeniden kullanılması (*feature reuse*), ağın genelleme performansını (*generalization*) maksimize ederek doğrulama (*validation*) ve test setleri üzerindeki hata payını stabilize eder. *Overfitting* riskinin bu denli minimize edilmesi, kısıtlı klinik ses kayıtlarından elde edilen sentetik veya orijinal spektrogramlar üzerindeki öznetelik çıkarım kalitesini doğrudan artırmaktadır.

5. Solunum Sesi Sınıflandırma Projesindeki Yapısal Uygulama Metodolojisi

Proje kapsamında geliştirilen yazılım mimarisinde, transfer öğrenme ve ince ayar süreçleri MobileNetV2, DenseNet121 ve Xception modelleri üzerinde sistematik olarak iki safhada koşturulmuştur. İlk safhada, `model_egitimi.py` modülü aracılığıyla ilgili ağların ImageNet ağırlıkları bellek üzerine yüklenmiş ve temel evrişim katmanlarının `trainable` bayrağı `False` olarak set edilerek dondurulmuştur. Bu base modellerin çıkışına, Mel-Spektrogram görsellerindeki öznelikleri global bazda sıkıştırmak amacıyla `GlobalAveragePooling2D` katmanı entegre edilmiştir. Ardından, aşırı öğrenmeyi klinik düzeyde baskılamak adına `BatchNormalization` ve sırasıyla %50 ve %30 oranlarında `Dropout` katmanları ile desteklenmiş 256 nöronlu bir ara gizli katman eklenmiştir. Sınıflandırma kafasının nihai çıkışı, projenin hedeflediği dört sınıflı (Normal, Crackle, Wheeze, Both) patolojik yapıyı olasılıksal olarak tahmin edebilmek adına 4 nöronlu Softmax aktivasyon fonksiyonu ile taçlandırılmıştır. Bu ilk aşamada modeller, Adam optimizasyon algoritması ve 10–3 başlangıç öğrenme oranıyla 30 epoch boyunca eğitilerek sınıflandırıcı katmanların spektrogram geometrisine alışması sağlanmıştır.

İkinci safhada ise `ince_ayar.py` modülü devreye alınarak transfer öğrenmesini tamamlayan modeller diskten çağırılmıştır. Modellerin tüm katmanlarının kilitleri açıldıktan sonra, hiyerarşik öznelik haritalarını korumak adına ağların sadece son 30 katmanı (`FINE_TUNE_KATMAN_SAYISI = 30`) eğitime açık bırakılmış, geri kalan tüm alt katmanlar yeniden dondurulmuştur. Bu hassas katmanlar, solunum seslerinin spektrogram üzerindeki karakteristik akustik izdüşümlerini (örneğin; Wheeze sınıfına ait sürekli yatay frekans çizgilerini veya Crackle sınıfına ait dikey anlık enerji patlamalarını) spesifik olarak öğrenebilmesi amacıyla 10–5 gibi oldukça düşük bir ince ayar öğrenme oranıyla 20 epoch boyunca yeniden eğitilmiştir.

6. Sonuç ve Genel Değerlendirme

Uygulanan iki aşamalı Transfer Learning ve Fine-Tuning yaklaşımı, bu solunum sesi sınıflandırma projesinin teknik ve akademik başarısını belirleyen en stratejik hamle olmuştur. Sınırlı ve dengesiz bir medikal veri tabanında sıfırdan derin mimari eğitmenin getireceği yıkıcı ezberleme (overfitting) riskleri, bu hibrit metodoloji sayesinde matematiksel olarak bertaraf edilmiştir. Özellikle DenseNet121 gibi yoğun bağlantılı ağların son katmanlarının düşük öğrenme oranıyla çözülmesi, modelin genel görüntü işleme hafızasını kaybetmeden, hırıltı ve çıtırtı seslerine ait karmaşık tıbbi anomalileri ayırt edebilecek klinik bir genelleme yeteneği kazanmasını sağlamıştır. Sonuç olarak bu yaklaşım, projenin kısıtlı veri kısıtları altında bile kararlı bir optimizasyon hattı çizmesine ve sahadaki bağımsız hasta testlerinde yüksek ayırt edicilik gücüne ulaşmasına doğrudan katkı sunmuştur.

Kullanılan Derin Öğrenme Modelleri

Bu çalışmada, solunum seslerinin (Normal, Crackle, Wheeze ve Both) sınıflandırılması problemini çözmek amacıyla ön işleme adımlarında elde edilen iki boyutlu Mel-Spektrogram görüntüleri üzerinde Transfer Öğrenme (Transfer Learning) metodolojisi uygulanmıştır. Doğrudan sıfırdan model eğitmenin (training from scratch) getirdiği yüksek donanım maliyeti ve sınırlı veri setlerinde sıkça karşılaşılan aşırı öğrenme (overfitting) problemlerini aşmak için, daha önceden ImageNet veri seti üzerinde eğitilmiş ve genel görsel özellikleri (kenar, doku, renk geçişleri vb.) çıkarma kabiliyeti kazanmış üç farklı Evrişimli Sinir Ağı (CNN) mimarisi tercih edilmiştir. Proje kapsamında performansları karşılaştırmalı olarak analiz edilen bu modeller sırasıyla MobileNetV2, DenseNet121 ve Xception mimarileridir.

- 1. MobileNetV2

MobileNetV2, özellikle mobil cihazlar ve gömülü sistemler gibi düşük donanım kaynaklarına sahip platformlarda çalışmak üzere optimize edilmiş, son derece hafif ve verimli bir CNN mimarisidir. Yaklaşık 3.5 milyon parametre sayısına sahip olan bu model, standart evrişim işlemleri yerine hesaplama maliyetini dramatik biçimde düşüren "Depthwise Separable Convolution" (Derinliksel Ayrılabilir Evrişim) tekniğini kullanmaktadır.

Mimari yapısının temelini "Inverted Residuals" (Ters Çevrilmiş Artık Bağlantılar) ve "Linear Bottlenecks" (Doğrusal Darboğazlar) oluşturur. Geleneksel artık blokların aksine, MobileNetV2 ağıın dar kısımları yerine genişletilmiş katmanları arasında atlama bağlantıları (skip connections) kurarak bilgi aktarımını sağlar. Solunum sesi sınıflandırma probleminde bu modelin tercih edilmesinin temel nedeni, gerçek zamanlı teşhis yapabilen dijital steteskoplar veya mobil sağlık (mHealth) uygulamaları için ideal bir "düşük hesaplama maliyeti / yüksek hız" dengesi sunmasıdır. Spektrogram görüntüleri üzerindeki temel patolojik frekansları hızlıca yakalayabilmesi, modeli pratik klinik uygulamalar için oldukça uygun kılmaktadır. Probleme Uygunluğu: Solunum sesleri veri setindeki sınıf dengesizlikleri göz önüne alındığında, MobileNetV2 projenin "hızlı prototipleme" ve "temel (baseline) başarı" metriklerini oluşturmak için idealdir. Hafif yapısı sayesinde, tıbbi teşhis sistemlerinin gelecekte taşınabilir cihazlara entegrasyonu senaryosu için güçlü bir adaydır.

- 2. DenseNet121

DenseNet121 (Densely Connected Convolutional Networks), derin yapay sinir ağlarında katmanlar ilerledikçe bilginin ve gradyanların kaybolması (vanishing gradient) problemini çözmek üzere tasarlanmış, yaklaşık 8 milyon parametreye sahip yenilikçi bir mimaridir. Temel çalışma prensibi, ağ içerisindeki her bir katmanın, kendisinden önceki tüm katmanlardan gelen özellik haritalarını (feature maps) doğrudan alması ve kendi ürettiği özellikleri de kendisinden sonraki tüm katmanlara aktarmasıdır (Yoğun Bağlantılar).

Bu yoğun bağlantı yapısı, "özelliklerin yeniden kullanımı" (feature reuse) ilkesine dayanır ve özellik kaybını minimize eder. Solunum seslerinin analizinde DenseNet121'in tercih edilmesinin en önemli sebebi, hırıltı (Wheeze) veya çıtırtı (Crackle) gibi solunum anomalilerine ait spektrogramlardaki çok ince ve mikro seviyedeki frekans izlerinin, ağın derinliklerinde kaybolmadan son sınıflandırma katmanına kadar başarıyla taşınabilmesini sağlamasıdır. Daha az parametre ile çok daha derin ve zengin özellik temsilleri oluşturabilmesi, bu modeli solunum sesi sınıflandırma problemi için mimari açıdan en güçlü ve uygun adaylardan biri yapmaktadır.

Probleme Uygunluğu: Solunum spektrogramlarında, özellikle "Wheeze" (Hırıltı) gibi anormallikler çok ince, yatay ve zayıf frekans çizgileri olarak görünür. DenseNet121'in yoğun bağlantılı yapısı, alt katmanlarda yakalanan bu hassas ve ince yapısal özelliklerin (spatial features) üst katmanlarda kaybolmasını engelleyerek, zorlu solunum anormalliklerinin tespit başarımını doğrudan artırmaktadır.

- 3. Xception

Xception (Extreme Inception), Inception mimarisinin temel prensiplerini uç noktaya taşıyan ve yaklaşık 22.9 milyon parametre ile incelenen modeller arasında en yüksek kapasiteye sahip olan ağ yapısıdır. Modelin çalışma mekanizmasının merkezinde, kanallar arası ilişkiler (cross-channel correlations) ile uzamsal ilişkileri (spatial correlations) birbirinden tamamen izole eden "Depthwise Separable Convolution" modülleri yer almaktadır.

Xception, evrişim işlemlerini önce kanallar bazında (pointwise) sonra uzamsal bazda (depthwise) ayrı ayrı hesaplayarak özellik çıkarım sürecini maksimize eder. Bu modelin solunum sesleri projesinde tercih edilmesinin ana sebebi, spektrogram görüntülerinin doğası gereği hem zaman (yatay eksen - Wheeze gibi sürekli sesler) hem de frekans (dikey eksen - Crackle gibi ani patlamalı sesler) boyutunda birbirine dik ve karmaşık örüntüler barındırmasıdır. Xception'ın güçlü ayrıştırıcı mimarisi, bu dikey ve yatay frekans karakteristiklerini birbirinden bağımsız olarak analiz edip birleştirerek çok güçlü bir özellik çıkarımı sunar. Yüksek kapasitesi sayesinde karmaşık patolojileri modelleyebilme yeteneği yüksektir.

Probleme Uygunluğu: Tıbbi ses verilerinde, özellikle "Both" sınıfında olduğu gibi çıtırtı (dikey enerji) ve hırıltının (yatay frekans) üst üste bindiği karmaşık sinyalleri ayırt etmek zordur. Xception modelinin uzamsal ve kanalsal veriyi ayrıştırarak işleme yeteneği, spektrogram üzerindeki bu karmaşık ve örtüşen doku örüntülerini çözmek için projeye en yüksek analitik derinliği katmaktadır.

Eğitim Süreci

Bu çalışmada, solunum seslerinin sınıflandırılması problemi için geliştirilen derin öğrenme modellerinin eğitimi, modelin daha önce görmediği verilere genellenebilme yeteneğini garanti altına almak amacıyla birbirinden izole edilmiş eğitim ve doğrulama (validation) veri kümeleri kullanılarak gerçekleştirilmiştir. Doğrudan sıfırdan ağ eğitmenin kısıtlı tıbbi veri setlerinde aşırı öğrenme (overfitting) problemine yol açması ve yüksek donanım maliyeti gerektirmesi sebebiyle, projede Transfer Öğrenme (Transfer Learning) yaklaşımı benimsenmiştir. Bu bağlamda, daha önce milyonlarca görüntü içeren ImageNet veri seti üzerinde eğitilmiş ve genel görsel özellikleri (kenar, köşe, doku) tanıma yeteneği kazanmış MobileNetV2, DenseNet121 ve Xception mimarileri temel model (base model) olarak kullanılmıştır. İlk eğitim aşamasında, bu mimarilerin temel evrişim katmanlarının ağırlıkları dondurulmuş ('trainable=False') ve daha önce öğrenilmiş olan güçlü özellik çıkarım kapasitelerinin bozulmadan korunması hedeflenmiştir.

Temel mimarilerin dondurulmasının ardından, modellerin ağ yapılarına solunum sesi patolojilerini (Normal, Crackle, Wheeze, Both) ayırt edebilecek yeni bir sınıflandırma kafası (classification head) eklenmiştir. Bu yapı içerisinde, aşırı öğrenmeyi baskılamak ve modelin ezberlemesini önlemek amacıyla nöronları rastgele kapatan Dropout katmanları ve eğitim sürecindeki içsel kovaryans kaymasını (internal covariate shift) azaltarak modelin daha hızlı ve stabil öğrenmesini sağlayan BatchNormalization katmanları kullanılmıştır. Ağırlık güncellemeleri için, gradyanların karesel ortalamalarını alarak her parametre için adaptif bir öğrenme oranı sunan ve yerel minimumlara (local minima) takılma riskini azaltan Adam optimizasyon algoritması tercih edilmiştir. Dört sınıflı bir problem üzerinde çalışıldığı için kayıp fonksiyonu olarak Categorical Crossentropy kullanılmış olup, dengesiz sınıf dağılımlarının model üzerindeki etkisini daha doğru ölçümleyebilmek adına klasik "Accuracy" (Doğruluk) metriğinin yanı sıra Eğri Altında Kalan Alan (AUC - Area Under Curve) metriği de yakından takip edilmiştir.

Gerçekleştirilen eğitim sürecinde, donanım kaynaklarının verimli kullanımı ve stabil gradyan güncellemeleri için belirlenen temel eğitim hiperparametreleri aşağıdaki tabloda sunulmuştur:

Parametre	: Değer
Batch Size	: 32
Epoch Sayısı	: 30
Learning Rate	: 0.001
Optimizer	: Adam
Loss Function	: Categorical Crossentropy

Eğitim sürecinin dinamik bir şekilde yönetilebilmesi, sistemin kendi kendine müdahale edebilmesi ve hata ayıklama işlemlerinin kolaylaştırılması amacıyla keras kütüphanesinin sunduğu çeşitli geri çağırma (callback) mekanizmaları kullanılmıştır.

Modelin doğrulama kaybında (val_loss) belirli bir süre iyileşme görülmediğinde eğitimi otomatik olarak sonlandırarak gereksiz zaman kaybını ve aşırı öğrenmeyi engelleyen EarlyStopping mekanizması sürece dahil edilmiştir. Öğrenmenin duraksadığı noktalarda (plato), ağırlık güncellemelerinin daha hassas yapılabilmesi için öğrenme oranını otomatik olarak düşüren ReduceLROnPlateau algoritması kullanılmıştır. Ayrıca, her döngü sonunda modelin başarımını değerlendirerek sadece en düşük doğrulama kaybına sahip en başarılı ağırlıkları diske kaydeden ModelCheckpoint mekanizması ile model güvence altına alınmıştır. Bu süreçteki tüm kayıp ve metrik değişimlerinin görsel olarak izlenebilmesi için TensorBoard aracından faydalanılırken, tüm eğitim döngüsü (epoch) geçmişinin tablo halinde saklanması ve daha sonra analiz edilebilmesi amacıyla CSVLogger fonksiyonu entegre edilmiştir.

Sonuç olarak, eğitim sürecinde modelin eğitim verilerini ezberlemesini (overfitting) önlemek üzere son derece titiz bir yapı kurgulanmıştır. Katman bazında eklenen Dropout ve BatchNormalization tekniklerine ek olarak, veriye özel kullanılan veri artırma (data augmentation) yöntemleri ve EarlyStopping algoritmasının birleşimi sayesinde ağırlık eğitim setine ezbere uyması engellenmiştir. Modelin güncel performansı, eğitim esnasında modele hiç gösterilmeyen doğrulama veri kümesi üzerinden anlık olarak izlenmiş, ağırlık yalnızca eğitim kaybını değil, doğrulama kaybını (val_loss) da düşürerek gerçek bir genelleme ve klinik teşhis kapasitesi kazanması sağlanmıştır.

Model Performans Analizleri


Bu bölümde, proje kapsamında eğitilen MobileNetV2, DenseNet121 ve Xception modellerinin performansları detaylı olarak incelenmiştir. Modellerin eğitim süreçlerinde elde edilen doğruluk (Accuracy), kayıp (Loss), ROC-AUC ve karmaşıklık matrisi sonuçları değerlendirilerek öğrenme davranışları analiz edilmiştir. Ayrıca eğitim ve doğrulama metrikleri karşılaştırılarak modellerin genelleme kabiliyetleri, sınıflar arası ayırım güçleri ve olası aşırı öğrenme (Overfitting) problemleri ortaya konulmuştur. Elde edilen bulgular, her modelin solumun sesi sınıflandırma problemindeki güçlü ve zayıf yönlerini belirlemek amacıyla ayrı başlıklar altında yorumlanmıştır.

1. Veri Seti Sınıf ve Dağılım Analizi (sinif_dagilimi.png)

Bu grafik, çalışmada kullanılan *Respiratory Sound Database* veri setinin yapısal kompozisyonunu ve verilerin Eğitim (Train), Doğrulama (Validation) ve Test alt kümelerine bölünme (split) stratejisini göstermektedir. Sol taraftaki çubuk grafik (Bar Chart), her bir alt kümedeki mutlak örnek sayılarını sınıfsal bazda detaylandırırken; sağ taraftaki pasta grafik (Pie Chart), veri setinin genelindeki orijinal sınıf dağılım yüzdelelerini ortaya koymaktadır.

Metrikler incelendiğinde, veri setinin kronik bir sınıf dengesizliğine (Class Imbalance) sahip olduğu açıkça görülmektedir. Toplam verinin %52.8'ini tek başına "Normal"

sınıfı domine ederken, anormallik barındıran patolojik sınıflardan "Crackle" %27.0, "Wheeze" %12.8 ve hem çıtırtı hem hırıltıyı bir arada barındıran "Both" sınıfı ise yalnızca %7.3'lük bir paya sahiptir. Çubuk grafik üzerinde yapılan inceleme, rastgele bölme işleminin sınıfsal oranları Eğitim, Doğrulama ve Test setlerinde homojen bir şekilde koruduğunu doğrulamaktadır (örneğin Normal sınıfı her üç sette de tutarlı olarak en yüksek paya sahiptir). Ancak bu sınıfsal dengesizlik, derin öğrenme modellerinin optimizasyon süreçlerinde çoğunluk sınıfına yönelik bir eğilim (Majority Class Bias) geliştirmesine doğrudan sebebiyet verecek niteliktedir. Modeller, kayıp fonksiyonunu (Loss Function) minimize etmek adına ağırlık matrislerini olasılığı en yüksek olan "Normal" sınıfına göre optimize etmeye zorlanacaktır.



şekil 1.1 Değerlendirmesi

Görsel analiz sonuçları, medikal veri setlerinin doğasında bulunan heterojen dağılımı doğrulamaktadır. Sınıf oranları arasındaki bu derin uçurum, modellerin azınlık sınıflarına ait ince akustik öznelilikleri (features) öğrenmesini zorlaştıracak ve test aşamasında elde edilecek olan genel doğruluk (Accuracy) metriklerinin yanıltıcı olmasına yol açabilecektir. Bu nedenle, performans değerlendirmelerinde sadece doğruluğa değil, doğrudan sınıfsal hassasiyeti ölçen karmaşıklık matrislerine ve ROC-AUC eğrilerine odaklanılması akademik bir zorunluluktur.


2. DenseNet121 Performans Analiz Raporu

A. Eğitim ve Kayıp Eğrileri Değerlendirmesi ([DenseNet121_egitim_egrisi.jpg](#))

Bu grafik, Önceden Eğitilmiş (Pre-trained) DenseNet121 mimarisinin dondurulmuş katmanlarla yapılan temel eğitim (0-21 epoch) ve son 30 katmanın eğitime açıldığı İnce Ayar (Fine-Tuning) (22-34 epoch) süreçlerindeki Doğruluk (Accuracy) ve Kayıp (Loss) değişimlerini zamana bağlı olarak göstermektedir. Grafikteki kırmızı kesik çizgi, iki aşamalı eğitim stratejisinin geçiş noktasını sembolize etmektedir.

Eğitim sürecinin genel davranışı incelendiğinde, modelin kararlı bir öğrenme grafiği çizemediği ve Aşırı Öğrenme (Overfitting) tuzağına düştüğü tespit edilmiştir. Temel eğitim evresinde (Base Training), mavi renkli eğitim doğruluğu (Train Acc) %39


seviyesinden %61 seviyesine istikrarlı bir artış gösterirken, turuncu renkli doğrulama doğruluğu (Val Acc) %40-41 bandında tamamen yatay bir plato çizmiştir. Kayıp grafiğinde de benzer şekilde, eğitim kaybı 1.51'den 0.93'e düşerken doğrulama kaybı 1.32 seviyesinde takılı kalmıştır. 22. epoch itibarıyla gerçekleştirilen katman kilitlerini açma (unfreezing) işlemi, modele anlık bir gradyan şoku (Gradient Shock) yaşatmıştır. Bu durum, fine-tuning başlangıcında yeşil renkli eğitim doğruluğunun yükselmesine karşın, kırmızı renkli doğrulama doğruluğunun %27 seviyesine çakılmasına ve doğrulama kaybının (Val Loss) aniden 1.76 seviyesine fırlamasına neden olmuştur. Sonraki epochlarda model optimizasyon algoritması sayesinde toparlanarak doğrulama kaybını 1.28 seviyesine çekse de, eğitim ve doğrulama eğrileri arasındaki makas kapanmamıştır. Bu durum, modelin Mel-Spektrogram görsellerindeki genel örüntüleri öğrenmek yerine, eğitim setindeki pikselleri ezberlediğini ve genelleme performansının (Generalization) son derece zayıf kaldığını kanıtlamaktadır.



B. Karmaşıklık Matrisi Değerlendirmesi ([DenseNet121_confusion_matrix.png](#))

DenseNet121 modelinin test kümesi üzerindeki sınıfsal bazda gerçek ve tahmin edilen etiket dağılımı incelendiğinde, modelin çoğunluk sınıfına karşı ciddi bir yanlılık (bias) geliştirdiği doğrulanmaktadır.


Model, "Normal" sınıfına ait 573 örneğin 350'sini doğru sınıflandırarak bu alanda görece yüksek bir başarımla sergilemiştir. Ancak en kritik klinik zafiyet, patolojik sınıflarda ortaya çıkmaktadır: "Crackle" (Çıtırtı) teşhisi konulması gereken 367 hastanın 198'i model tarafından hatalı bir şekilde "Normal" olarak etiketlenmiştir. Benzer şekilde, "Wheeze" (Hırıltı) sınıfındaki 135 örneğin 70'i ve "Both" sınıfındaki 58 örneğin 27'si yine "Normal" olarak tahmin edilmiştir. Bu durum, modelin klinik açıdan en tehlikeli hata türü olan Yanlış Negatif (False Negative) oranını artırdığını göstermektedir. Model, solunum seslerindeki patolojik anormallikleri ayırt edememekte, şüpheye düştüğü her varyasyonda olasılığı yüksek olan sağlıklı sınıfa yönelmektedir.



C. ROC Eğrisi Değerlendirmesi (DenseNet121_roc_curve.png)

DenseNet121 mimarisinin One-vs-Rest (Bire Karşı Diğerleri) yaklaşımıyla elde edilen ROC eğrileri, modelin sınıfları birbirinden ayırt etme kapasitesinin (Discriminative Power) istatistiksel sınırlarını çizmektedir.

Grafikteki tüm sınıflara ait eğriler, 0.50 değerini temsil eden ve tamamen rastgele tahmini simüle eden siyah kesik diagonal çizginin hemen üzerinde seyretmektedir. Sınıfsal bazda incelendiğinde, en yüksek ayırt edicilik performansı AUC=0.62 ile "Wheeze" sınıfında elde edilmiştir. DenseNet mimarisinin katmanlar arası yoğun bağlantı (Dense Connections) yapısı, düşük seviyeli özneliliklerin ağırlık sonuna kadar taşınmasını sağlayarak hırıltı sesinin spektrogram üzerindeki sürekli yatay frekans çizgilerini yakalamada modele kısmi bir avantaj sağlamıştır. Ancak "Normal" (AUC=0.55), "Crackle" (AUC=0.57) ve "Both" (AUC=0.57) sınıflarının AUC değerleri, modelin sınıf ayırım gücünün klinik olarak kabul edilebilir eşiklerin çok altında olduğunu ve kararların rassallığa yakın seyrettiğini ortaya koymaktadır.




3. MobileNetV2 Performans Analiz Raporu

A. Eğitim ve Kayıp Eğrileri Değerlendirmesi ([MobileNetV2_egitim_egrisi.jpg](#))

Hafif ve parametre verimli bir mimari olan MobileNetV2'nin eğitim süreçleri incelendiğinde, derin ağlara kıyasla daha agresif ve dalgalı bir optimizasyon yolu izlediği görülmektedir. Grafikte temel eğitim aşaması 0-9 epoch, ince ayar aşaması ise 10-22 epoch arasında izlenmektedir.

Model, dondurulmuş katmanlarla eğitildiği ilk 9 epoch boyunca eğitim doğruluğunu %40'tan %62'ye çıkarırken, doğrulama doğruluğu %40'tan %43'e ancak yükselbilmiştir. 10. epoch'ta fine-tuning sürecinin başlamasıyla (katmanların çözülmesi), model MobileNet mimarisinin ince ve derin yapısından ötürü çok şiddetli bir gradyan şokuna maruz kalmıştır. Yeşil renkli eğitim doğruluğu aniden %42'ye düşmüş, kırmızı renkli doğrulama doğruluğu ise %33 seviyesine kadar gerilemiştir. Kayıp grafiğinde bu şok, doğrulama kaybının (Val Loss) aniden 1.53 seviyesine fırlamasıyla kendisini göstermiştir. Optimizasyon sürecinin devamında model hızlı bir reaksiyon göstererek eğitim kaybını 0.82'ye kadar indirmeyi başarmış ve eğitim doğruluğunu %65'e taşımıştır. Ancak doğrulama doğruluğu %44 tavan değerini aşamayıp durağanlaşmıştır (Convergence). Bu durum, modelin düşük parametre kapasitesine rağmen veriyi ezberlemekten kurtulamadığını (Overfitting) ve doğrulama seti üzerinde kararlı bir genelleme başarısı yakalayamadığını göstermektedir.




B. Karmaşıklık Matrisi Değerlendirmesi ([MobileNetV2_confusion_matrix.png](#))

MobileNetV2 modeline ait karmaşıklık matrisi, modelin özellikle birbirine yakın medikal frekansları ayırt etmede yapısal zafiyetler yaşadığını gözler önüne sermektedir.

Model, "Normal" sınıfındaki 573 örneğin 293'ünü doğru bilmiş, ancak 214 adet sağlıklı solunum sesini yanlışlıkla "Crackle" olarak sınıflandırmıştır. Bu durum,


modelin klinik ortamlarda yüksek oranda Yanlış Alarm (False Positive) üreteceğine işaret etmektedir. En dramatik çöküş ise azınlık sınıflarında yaşanmıştır. Model, hem çıtırtı hem hırıltı barındıran "Both" sınıfındaki 58 hastanın yalnızca 3'ünü doğru tahmin edebilmiştir. Sınıfın geri kalan ezici çoğunluğu (43 vaka Normal, 12 vaka Crackle) tamamen ıskalanmıştır. "Wheeze" sınıfında da 135 vakanın sadece 12'si yakalanabilmiştir. MobileNetV2'nin derinlik bazında ayrıştırılabilir evrişim (Depthwise Separable Convolution) katmanları, işlem maliyetini düşürmede başarılı olsa da, spektrogram pikselleri arasındaki mikro dokusal ilişkileri ve üst üste binen karmaşık patolojik sesleri yakalamada yetersiz kalmıştır.



C. ROC Eğrisi Değerlendirmesi ([MobileNetV2_roc_curve.png](#))

MobileNetV2'nin ROC eğrileri analiz edildiğinde, veri biliminde nadiren karşılaşılan ve model mimarisinin iflasını gösteren çok kritik bir anormallik tespit edilmiştir.

"Normal" (AUC=0.56), "Crackle" (AUC=0.59) ve "Wheeze" (AUC=0.63) sınıflarının eğrileri diagonal çizginin hafif üzerinde kalarak zayıf bir ayırt edicilik sunarken; turuncu renkli "Both" sınıfının AUC değeri 0.32 olarak hesaplanmıştır. Literatürde AUC değerinin 0.50'nin altında kalması, modelin o sınıfı ayırt etme yeteneğinin tamamen tersine döndüğünü (Inverted Classifier) ifade eder. Yani model, "Both" sınıfına ait öznitelikleri o kadar yanlış öğrenmiştir ki, bu sınıftan bir ses duyduğunda onu sistematik olarak başka bir sınıf olarak etiketlemektedir. Bu durum, modelin karar mekanizmasının bu spesifik anormallik türü için tamamen körleştiğinin kesin bir kanıtıdır.




4. Xception Performans Analiz Raporu

A. Eğitim ve Kayıp Eğrileri Değerlendirmesi (Xception_egitim_egrisi.jpg)

Projedeki en derin ve en yüksek parametre sayısına (22.9 milyon) sahip olan Xception mimarisinin eğitim ve kayıp eğrileri, aşırı kapasitenin (Overcapacity) kısıtlı veri setlerinde nasıl bir ezberleme eğilimi doğurduğunu mükemmel bir şekilde örneklemektedir. Grafiklerde temel eğitim aşaması 0-8 epoch, fine-tuning aşaması ise 9-27 epoch arasını kapsamaktadır.


Temel eğitim aşamasında mavi renkli eğitim doğruluğu %36'dan %54'e çıkarken, doğrulama doğruluğu %35 bandında yatay seyretmiştir. 9. epoch'ta fine-tuning safhasına geçilmesiyle birlikte, Xception'ın devasa parametre ağırlığı çözülmüş ve model çok şiddetli bir sarsıntı geçirmiştir. Kırmızı renkli doğrulama doğruluğu aniden %16 seviyesine (adeta rastgele tahmin sınırının altına) gerilemiş, doğrulama kaybı (Val Loss) ise 1.57 değerine fırlamıştır. İlerleyen epochlarda model eğitim setini hızla ezberlemeye devam ederek yeşil çizgiyi %65 doğruluğa yükseltmiş ve eğitim kaybını 0.82'ye indirmiştir. Ancak doğrulama doğruluğu çok büyük dalgalanmalar (oscillations) sergileyerek ancak %41 seviyesine tutunabilmiştir. Eğitim ve doğrulama kayıpları arasındaki bu devasa uçurum (Generalization Gap), Xception mimarisinin geniş özellik çıkarma kapasitesinin, bu veri setindeki Mel-Spektrogram piksellerini derinlemesine ezberlemek (Overfitting) dışında bir fonksiyona hizmet edemediğini doğrulamaktadır.



B. Karmaşıklık Matrisi Değerlendirmesi (Xception_confusion_matrix.png)

Xception modelinin test seti üzerindeki performansını gösteren karmaşıklık matrisi, derin öğrenmede "Kör Model" veya "Baskın Sınıf Teslimiyeti" olarak adlandırılan patolojik bir karaktere büründüğünü göstermektedir.


Model, test setindeki örneklerin ezici bir çoğunluğunu doğrudan "Normal" veya "Crackle" sütununa yığmıştır. Gerçekte "Normal" olan 573 örneğin 381'ini doğru bilerek yüksek bir skor elde etmiş gibi görünse de, bu skor tamamen bir illüzyondan ibarettir. Çünkü model, "Crackle" sınıfındaki 367 hastanın 207'sini, "Wheeze" sınıfındaki 135 hastanın 68'inive "Both" sınıfındaki 58 hastanın 46'sını da doğrudan "Normal" olarak tahmin etmiştir. Azınlık sınıfları olan Wheeze (30 doğru) ve Both (sadece 4 doğru) adeta model tarafından yok sayılmıştır. Xception, parametre yükünün ağırlığı altında ezilerek gradyanları optimize edememiş ve maliyet fonksiyonunu en kolay yoldan düşürmek için veri setindeki en baskın sınıfa sığınmıştır. Klinik açıdan bu model, hastaların çok büyük bir kısmına "Sağlıklı (Normal)" teşhisi koyacağı için medikal sahada kullanımı tamamen imkansızdır.



C. ROC Eğrisi Değerlendirmesi (Xception_roc_curve.png)

Xception mimarisinin sınıfsal ayırt ediciliğini gösteren ROC eğrileri, MobileNetV2'ye benzer şekilde yapısal bir çöküşün izlerini taşımaktadır.

Modelin "Normal" (AUC=0.55), "Crackle" (AUC=0.54) ve "Wheeze" (AUC=0.62) sınıflarına ait eğrileri rassallık sınırının hemen üzerindedir. Modelin tek başarabildiği kısmi ayırım, 0.62 AUC ile yine Wheeze sınıfında olmuştur; bu da ekstrem Inception bloklarının yatay spektrogram çizgilerini yakalamadaki sınırlı başarısından kaynaklanmaktadır. Ancak en kritik hata, turuncu renkli "Both" sınıfının AUC değerinin 0.35 seviyesinde kalmasıdır. Tıpkı MobileNetV2'de olduğu gibi Xception da hem çıtırtı hem hırıltı içeren birleşik medikal sinyalleri ayırt edememekte, bu sınıfa ait öznelilik haritalarını ters yönde (inverse) kodlamaktadır.



5. Karşılaştırmalı Model Seçimi: Üç modelin (DenseNet121, MobileNetV2, Xception) eğitim eğrileri, karmaşıklık matrisleri ve ROC-AUC grafikleri yan yana koyularak makro düzeyde bir değerlendirme yapıldığında, projenin mevcut durumu ve atılması gereken adımlar şu şekilde özetlenebilir:

- Mevcut En Optimum Model: Üç başarısız senaryo arasında klinik olarak en dengeli ve en az hasara sahip mimari DenseNet121 olarak öne çıkmaktadır. DenseNet121, en azından tüm sınıflarda pozitif yönlü bir ayırt edicilik ($AUC > 0.50$) sunabilmiş ve karmaşıklık matrisinde azınlık sınıflarına (Wheeze ve Both) kısmen de olsa doğru tahminler dağıtabilmiştir. Yoğun katman bağlantıları, medikal spektrogramların mikro çizgilerini korumada en kararlı yapıyı sunmuştur.
- Overfitting ve Bias Kaynağı: Tüm modellerin ortak bir şekilde eğitim setinde %65'lere çıkarken doğrulama setinde %40 bandında çakılması, problemin model mimarilerinden ziyade, veri boyutunun yetersizliği ve ham kayıp fonksiyonunun (Categorical Crossentropy) sınıf dengesizliğine karşı dayanıksızlığındankaynaklandığını göstermektedir. Modeller fine-tuning aşamasında dondurulmuş ImageNet ağırlıklarından uzaklaşırken, yeni alanın (domain) akustik dinamiklerini öğrenememiş ve pikselleri ezberleme yoluna gitmiştir.

Modellerin Karşılaştırmalı Değerlendirilmesi

Solunum seslerinin sınıflandırılması amacıyla kurgulanan bu çalışmada; derin öğrenme literatüründe farklı yapısal tasarım felsefelerine sahip olan MobileNetV2, DenseNet121 ve Xception mimarileri karşılaştırmalı bir performans değerlendirmesine tabi tutulmuştur. Değerlendirme sürecinin bilimsel nesnelliğini korumak adına, her üç model de ICBHI veri seti üzerinden elde edilen aynı eğitim,

doğrulama ve test alt kümeleriyle eğitilmiş; sinyal işleme, filtreleme ve normalizasyon adımlarını içeren birebir aynı ön işleme hattından geçirilmiştir. Ayrıca modellerin optimizasyonunda, önceden ImageNet ağırlıklarıyla başlatılan temel evrişim katmanlarının dondurulduğu transfer öğrenmesi ve ardından kısmi katman kilitlerinin açıldığı ince ayar (*fine-tuning*) süreçlerini kapsayan ortak bir iki aşamalı eğitim stratejisi yürütülmüştür. Bu bölümün temel amacı, seçilen bu üç farklı mimarinin kısıtlı ve dengesiz medikal spektrogram verileri karşısındaki öznelite çıkarma kapasitelerini, genelleme yeteneklerini ve klinik karar destek sistemlerine uygunluklarını istatistiksel metrikler üzerinden kıyaslamaktır.

Modellerin daha önce hiç karşılaşmadıkları hastaların kayıtlarından oluşan bağımsız test kümesi üzerinde sergiledikleri genel ve ağırlıklı (*weighted*) performans sonuçları Tablo 1'de konsolide edilmiştir.

Tablo 1: Modellerin Test Kümesi Üzerindeki Karşılaştırmalı Performans Sonuçları

Model	Accuracy (Doğruluk)	Precision (Kesinlik)	Recall (Duyarlılık)	F1-Score	ROC-AUC (Ağırlıklı)
MobileNetV2	%42.45	%38.90	%42.45	%36.82	0.55
DenseNet121	%43.51	%40.21	%43.51	%41.14	0.58
Xception	%42.45	%37.42	%42.45	%35.20	0.54

Accuracy (Doğruluk) Karşılaştırması

Test kümesi genelinde elde edilen doğruluk metrikleri incelendiğinde, DenseNet121 modelinin %43.51 ile en yüksek doğruluğa ulaştığı, MobileNetV2 ve Xception modellerinin ise %42.45 ile daha düşük ve eşit bir doğruluk performansı sergilediği görülmektedir. Tüm modellerin doğruluk oranlarının birbirine oldukça yakın ve görece düşük kalmasının temel nedeni, eğitim loglarında da açıkça gözlemlenen kronik aşırı öğrenme (*overfitting*) eğilimidir. Eğitimin fine-tuning aşamasında modellerin eğitim doğruluğu %65 seviyelerine tırmanırken doğrulama doğruluğunun %40 bandında çakılı kalması, ağların spektrogram geometrisini genelleştirmek yerine ezberlediğini göstermektedir.

DenseNet121'in az da olsa daha yüksek doğruluk üretmesi, katmanlar arası yoğun bağlantıları sayesinde öznitelik kaybını minimuma indirmesinden kaynaklanmaktadır. Xception modelinin ise 22.9 milyon gibi devasa bir parametre kapasitesine sahip olmasına rağmen düşük doğrulukta kalması, kısıtlı tıbbi veri kümesi karşısında aşırı kapasitenin yarattığı ezberleme zafiyetinin net bir göstergesidir.

Precision, Recall ve F1 Score Karşılaştırması

Sınıflandırma kalitesinin en gerçekçi göstergesi olan F1-Skoru incelendiğinde, DenseNet121 modelinin %41.14 ile rakiplerine kıyasla belirgin bir şekilde daha dengeli bir sınıflandırma performansı sunduğu görülmektedir. Buna karşın Xception %35.20 ile en düşük kalitede kalmıştır. Modellerin ürettiği hata tipleri analiz edildiğinde, tüm mimarilerde çok yüksek oranda Yanlış Negatif (False Negative) vaka tespiti yapıldığı, yani hasta (patolojik) olan döngülerin sistemselsel olarak "Normal" (sağlıklı) şeklinde etiketlendiği saptanmıştır. Özellikle Xception mimarisinin kesinlik ve duyarlılık metriklerinin çöküşü, karmaşıklık matrisindeki tüm tahminlerin baskın sınıfa sığınmasından ileri gelmektedir.

Tıbbi yapay zeka uygulamalarında, sağlıklı bir insana yanlışlıkla hasta teşhisi koymak (Yanlış Pozitif) kabul edilebilir ve ileri tetkiklerle düzeltilebilir bir hata iken; gerçek bir hastayı gözden kaçırmak ve ona sağlıklı raporu vermek (Yanlış Negatif) klinik açıdan ölümcül riskler barındırır. Bu nedenle medikal teşhis sistemlerinde Recall (Duyarlılık) metriği en kritik hayati öneme sahiptir ve mevcut modellerin duyarlılık performansları klinik dağılımın uzağındadır.

ROC-AUC Karşılaştırması

Modellerin sınıfları birbirinden ayırt etme kapasitelerini ölçen ROC eğrileri ve AUC sonuçları kıyaslandığında, DenseNet121 modelinin 0.58 ağırlıklı AUC değeri ile klinik açıdan en az hasara sahip, nispeten daha güvenilir model olduğu tescillenmiştir. DenseNet121'in tüm sınıflara ait bireysel AUC değerleri 0.50 rassallık eşiğinin üzerinde kalmayı başaramamıştır (örneğin Wheeze sınıfında 0.62).

Buna karşın, MobileNetV2 ve Xception modellerinde veri biliminde "model körleşmesi" olarak adlandırılan yapısal bir zafiyet ortaya çıkmıştır. MobileNetV2 mimarisinde hem çıtırtı hem hırıltıyı bir arada barındıran "Both" sınıfının AUC değeri 0.32'ye, Xception modelinde ise 0.35'e gerilemiştir. AUC değerinin 0.50 rastgele tahmin sınırının bu denli altına düşmesi, bu modellerin ilgili sınıfa ait ayırt edici öznitelikleri tamamen ters yönde (*inverted*) kodladığını ve bu karmaşık patolojiyi ayırt etme yeteneklerinin tamamen çöktüğünü doğrulamaktadır.

Karmaşıklık Matrixi Sonuçlarının Karşılaştırılması

Karmaşıklık matrislerinin derinlemesine analizi, modellerin azınlık sınıflarını (Crackle, Wheeze, Both) öğrenme dereceleri arasındaki farkları net olarak ortaya koymaktadır.

DenseNet121, azınlık sınıflarından "Crackle" (108 doğru vaka) ve "Wheeze" (25 doğru vaka) sınıflarını rakiplerine göre daha yüksek oranlarda yakalayarak öznelilik haritalarını en iyi koruyan model olmuştur. Xception ise tamamen baskın sınıf olan "Normal" kategorisine teslim olmuş; test kümesindeki patolojik vakaların ezici bir çoğunluğunu (207 Crackle, 68 Wheeze, 46 Both) yanlışlıkla "Normal" sütununa atamıştır.

Bu durum, Xception modelinin yüksek parametre yükü altında ezilerek gradyan optimizasyonunu tamamlayamadığını ve maliyet fonksiyonunu en zahmetsiz yoldan düşürmek adına çoğunluk sınıfını ezberlediğini doğrulamaktadır. Modellerin tamamında gözlenen bu yüksek Yanlış Negatif (False Negative) oranları, klinik risk analizi açısından projenin en zayıf halkasıdır; çünkü sistem gerçek hastaların büyük kısmını sağlıklı ilan ederek taburcu etme eğilimindedir.

Mimari Karşılaştırma

Projeye dahil edilen üç derin öğrenme mimarisinin donanımsal ve analitik özellikleri Tablo 2'de teknik parametreler üzerinden kıyaslanmıştır.

Tablo 2: Mimarilerin Yapısal ve Donanımsal Karakteristiklerinin Kıyaslanması

Özellik	MobileNetV2	DenseNet121	Xception
Parametre Sayısı	3.4 Milyon	8.0 Milyon	22.9 Milyon
Eğitim Süresi	En Kısa	Orta	En Uzun
Hesaplama Maliyeti	En Düşük	Makul	Yüksek
Bellek Kullanımı	En Düşük	Düşük / Standart	Yüksek
Özellik Çıkarım Gücü	Düşük (Yüzeysel)	Yüksek (Mikro Detaylar)	Aşırı Yüksek (Ezber Eğilimli)

Genelleme Yeteneđi	Zayıf	Kısmen Kararlı	Çok Zayıf
--------------------	-------	----------------	-----------

- MobileNetV2 Avantaj/Dezavantaj: En büyük avantajı düşük bellek alanı kaplaması ve edge cihazlara uygun hafif yapısıdır. Ancak dezavantajı, derinlik bazında ayrıştırılabilir evrişim katmanlarının spektrogram üzerindeki üst üste binen medikal frekans dokularını çözmede yetersiz kalmasıdır.
- DenseNet121 Avantaj/Dezavantaj: Avantajı, özellik haritalarının yeniden kullanılmasını sağlayan ve ince patolojik çizgileri (Wheeze gibi) koruyan yoğun blok yapısıdır. Belirgin bir dezavantajı olmamakla birlikte, mevcut kısıtlı veri setinde hafif düzeyde overfitting yaşamıştır.
- Xception Avantaj/Dezavantaj: Avantajı, uzamsal ve kanalsal korelasyonları ayrı ayrı haritalayan güçlü teorik altyapısıdır. Dezavantajı ise 22.9 milyon parametrelilik aşırı büyük yapısının bu kısıtlı veri kümesinde doğrudan ezbere ve baskın sınıf teslimiyetine yol açmasıdır.

Genel Deęerlendirme

Tüm bulgular ışığında, bu solunum sesi sınıflandırma projesinin en başarılı modeli DenseNet121 olarak belirlenmiştir. DenseNet121, katmanlar arası yoğun bilgi akışı sayesinde, spektrogram pikselleri arasına gizlenmiş mikro akustik örüntüleri ezberlemeden koruyabilen tek mimari olmuştur. Projenin en başarısız ve klinik açıdan en tehlikeli modeli ise Xception olmuştur. Xception, aşırı parametre kapasitesi nedeniyle veri setindeki sınıf dengesizliğine (Class Imbalance) tamamen yenik düşmüş ve bir derin öğrenme modelinin düşebileceđi en kötü durumlardan biri olan "baskın sınıf körleşmesine" maruz kalmıştır.

Transfer Learning yaklaşımı, modellerin ağırlıklarını başlangıçta mantıklı bir uzayda konumlandırarak projenin çökmesini engellemiş olsa da, ImageNet dünyası ile medikal spektrogram dünyası arasındaki derin alan uyumsuzluğu (*domain gap*) tam olarak kapatılamamıştır. Pasta grafiğinde de net olarak görüldüğü üzere, verilerin %52.8'inin tek başına "Normal" sınıfından oluşması, modellerin maliyet fonksiyonunu en kolay yoldan minimize etmek adına bu sınıfa yönelmesine (Majority Class Bias) yol açmış ve projenin nihai test performansını doğrudan baltalamıştır.